

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**

Федеральное государственное автономное образовательное учреждение
высшего образования «Санкт-Петербургский политехнический
университет Петра Великого»

Институт компьютерных наук и кибербезопасности
Высшая школа технологий искусственного интеллекта

Направление: 02.03.01 «Математика и компьютерные науки»

Индивидуальное домашнее задание №4

по дисциплине

«Математическая статистика»

Вариант № 14

Студент,
группы 5130201/30102

_____ Санько В. В.

Преподаватель

_____ Малов С. В.

«_____» _____ 2026 г.

Санкт-Петербург, 2026

1 Часть 1. Регрессионный анализ

Данные

Параметры: $\alpha = 0.10$, $h = 1.80$.

$$Y = (11.83, 15.46, 18.12, \dots, 14.84, 13.92), \quad n = 50$$

$$X = (3, 2, 1, 3, 1, 3, 1, 3, \dots, 1, 2), \quad X \in \{0, 1, 2, 3\}$$

1.1 Задание А. Линейная регрессионная модель

Линейная регрессионная модель имеет вид:

$$Y = \beta_1 + \beta_2 X + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2).$$

Матрица плана $\mathbf{X}_l$ размера 2×50 ; МНК-оценка параметров:

$$\hat{\beta} = (\mathbf{X}_l \mathbf{X}_l^\top)^{-1} \mathbf{X}_l \mathbf{Y}.$$

МНК-оценки:

$$\hat{\beta}_1 = 15,6865, \quad \hat{\beta}_2 = -0,3474.$$

Построенная линия регрессии: $\hat{Y} = 15,6865 - 0,3474 X$.




Рис. 1: Линейная регрессионная модель. Синяя линия — оценка МНК.

Визуальная оценка: разброс точек значителен, линия почти горизонтальна, что указывает на слабую линейную зависимость Y от X .

1.2 Задание В. Полиномиальная модель

Добавим квадратичный член:

$$Y = \beta_1 + \beta_2 X + \beta_3 X^2 + \varepsilon.$$

Матрица плана $\mathbf{X}$ размера 3×50 ; МНК-оценка:

$$\hat{\beta} = (\mathbf{X}\mathbf{X}^\top)^{-1}\mathbf{X}\mathbf{Y}.$$

МНК-оценки полиномиальной модели:

$$\hat{\beta}_1 = 15,0769, \quad \hat{\beta}_2 = 1,0452, \quad \hat{\beta}_3 = -0,4302.$$




Рис. 2: Сравнение моделей: синяя — линейная, красная — квадратичная.

Визуальная оценка: обе кривые близки между собой, разброс точек велик. Квадратичный член незначительно улучшает подгонку.

1.3 Задание С. Гистограмма остатков. Проверка нормальности

Остатки полиномиальной модели: $\hat{\varepsilon} = \mathbf{Y} - \mathbf{X}^\top \hat{\beta}$.

Параметры гистограммы (шаг $h = 1,80$):

Границы	-5,84	-4,04	-2,24	-0,44	1,36	3,16	4,96
Частоты	6	6	9	14	7	6	2




Рис. 3: Гистограмма остатков. Красная кривая — плотность $N(0, s^2)$.

Тест χ^2 на нормальность (сложная гипотеза, оцениваем σ , $k = 7$, $\nu = k - 1 - 1 = 5$):

$$X^2 = 3,2804, \quad \chi_{5;0,90}^2 = 9,2364, \quad \text{Р-значение} = 0,6568.$$

Поскольку $X^2 = 3,28 < \chi_{5;0,90}^2 = 9,24$, **гипотеза о нормальности остатков принимается** на уровне значимости $\alpha = 0,10$.

1.4 Задание D. Доверительные интервалы для β_2 и β_3

При предположении нормальности ошибок и уровне доверия $1 - \alpha = 0,90$ строим частные доверительные интервалы:

Параметр	Оценка	Нижняя граница	Верхняя граница
β_1	15,0769	13,3829	16,7710
β_2	1,0452	-1,4047	3,4951
β_3	-0,4302	-1,1601	0,2996

Интерпретация:

- β_1 : интервал $[13,38; 16,77]$ не содержит нуль — параметр **значим**.
- β_2 : интервал $[-1,40; 3,50]$ содержит нуль — линейный эффект **не значим**.
- β_3 : интервал $[-1,16; 0,30]$ содержит нуль — квадратичный эффект **не значим**.

1.5 Задание E. Гипотезы линейности и независимости

Гипотеза линейности. $H_0 : \beta_3 = 0$ (квадратичная зависимость сводится к линейной).

Функционал $\psi = (0 \ 0 \ 1)\beta = \beta_3$, размерность $q = 1$.

$$F = \frac{(\mathbf{C}\hat{\beta})^\top [s^2 \mathbf{C}(\mathbf{X}\mathbf{X}^\top)^{-1}\mathbf{C}^\top]^{-1}(\mathbf{C}\hat{\beta})}{q} = 0,9783, \quad F_{1,47;0,90} = 2,8154.$$

$F = 0,98 < 2,82$ — гипотеза линейности принимается (Р-значение = 0,328).

Гипотеза независимости. $H_0 : \beta_2 = 0, \beta_3 = 0$ (Y не зависит от X).

Функционал $\psi = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \beta$, размерность $q = 2$.

$$F = 0,8931, \quad F_{2,47;0,90} = 2,4192.$$

$F = 0,89 < 2,42$ — гипотеза независимости принимается (Р-значение = 0,416).

1.6 Задание F. Выбор наилучшей модели (AIC и BIC)

Рассматриваем три модели:

- Модель (1): $E(Y | X) = \beta_1 + \beta_2 X$ (линейная),
- Модель (2): $E(Y | X) = \beta_1 + \beta_2 X + \beta_3 X^2$ (квадратичная),
- Модель (3): $E(Y) = \beta_1$ (константа, независимость от X).

Модель	Число параметров	AIC	BIC
(1) Линейная	3	254,76	260,49
(2) Квадратичная	4	255,73	263,38
(3) Константа	2	253,59	257,42

По обоим критериям наилучшей оказалась **модель (3) — константа**.

1.7 Задание G. Интерпретация результатов

1. Линейная модель: $\hat{Y} = 15,69 - 0,35 X$. Коэффициент $\hat{\beta}_2 = -0,35$ незначим.
2. Квадратичная модель: $\hat{Y} = 15,08 + 1,05 X - 0,43 X^2$. Оба коэффициента при X и X^2 незначимы.
3. Остатки квадратичной модели **нормально распределены** (тест χ^2 принят).
4. Нет статистических оснований утверждать нелинейность зависимости (тест на линейность принят).
5. Нет статистических оснований утверждать зависимость Y от X (тест на независимость принят).
6. По критериям AIC и BIC наилучшая модель — **константа**: $E(Y) = \beta_1$. Это согласуется с результатами тестов E.
7. **Вывод:** в данном наборе данных ковариата X не оказывает статистически значимого влияния на Y .

2 Часть 2. Двухфакторный дисперсионный анализ

Данные

Параметры: $\alpha_1 = 0,01$, $h = 1,40$. Число наблюдений $n = 40$, факторы A ($d_1 = 5$ уровней) и B ($d_2 = 4$ уровня).

2.1 Задание А. Двухфакторная модель. МНК-оценки

Полная модель с взаимодействием:

$$Y_{ijk} = \mu_{ij} + \varepsilon_{ijk}, \quad \varepsilon_{ijk} \stackrel{\text{i.i.d.}}{\sim} N(0, \sigma^2),$$

где $\mu_{ij} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij}$, $i = 1, \dots, 5$; $j = 1, \dots, 4$.

МНК-оценка через индикаторную матрицу $\mathbf{X}_M$ (20×40):

$$\hat{\boldsymbol{\mu}} = (\mathbf{X}_M \mathbf{X}_M^\top)^{-1} \mathbf{X}_M \mathbf{Y}.$$

Несмещённая оценка дисперсии:

$$s^2 = \frac{\text{SSE}}{n - d_1 d_2} = \frac{61,23}{40 - 20} = 3,0615.$$

Ячеечные средние $\hat{\mu}_{ij}$ (строки — уровни A , столбцы — уровни B):

	$B = 1$	$B = 2$	$B = 3$	$B = 4$
$A = 1$	19,44	20,39	16,02	16,75
$A = 2$	19,75	20,11	14,67	14,80
$A = 3$	20,87	21,24	15,45	16,80
$A = 4$	18,08	18,87	13,72	14,52
$A = 5$	—	17,84	10,36	13,51

2.2 Задание В. Аддитивность. График взаимодействия




Рис. 4: Зависимость $\hat{\mu}_{ij}$ от уровней фактора A при каждом фиксированном B .

Проверка взаимодействия: ANOVA для полной модели:

Источник	SS	Df	MS	F	P-значение
A	90,27	4	22,57	7,74	0,0005
B	221,53	3	73,84	25,33	$< 10^{-6}$
$A : B$	10,17	11	0,92	0,32	0,9733
Residuals	61,23	21	2,92		

P-значение для взаимодействия $A : B$ равно $0,9733 \gg 0,01$ — **взаимодействие не значимо**. На графике линии почти параллельны, что визуально подтверждает **аддитивность** модели.

2.3 Задание С. Анализ остатков. Нормальность




Рис. 5: Гистограмма остатков двухфакторной модели (шаг $h = 1,40$).

Параметры гистограммы:

Границы	-3,33	-1,93	-0,53	0,87	2,27	3,67
Частоты	2	10	20	7	1	

Тест χ^2 ($k = 5$, $\nu = k - 1 - 1 = 3$):

$$X^2 = 0,4237, \quad \chi_{3;0,99}^2 = 11,3449, \quad \text{P-значение} = 0,9353.$$

$X^2 = 0,42 \ll \chi_{3;0,99}^2 = 11,34$ — **гипотеза о нормальности принимается** на уровне $\alpha_1 = 0,01$.

2.4 Задание D. Дисперсионный анализ

Сравниваем вложенные модели с полной q (со взаимодействием). Остаточные степени свободы полной модели: $r = n - d_1 d_2 = 20$.

Гипотеза	SS_H	Df_H	MS_H	F	$F_{\alpha 1}$	P-знач.
H_{12} : нет $A:B$	10,17	11	0,92	0,317	3,294	0,973
H_1 : нет A	82,34	15	5,49	1,883	3,088	0,089
H_2 : нет B	231,70	14	16,55	5,676	3,130	0,0002
H_0 : нет A и B	321,96	18	17,89	6,135	2,989	0,0001
Ошибка	61,23	20	3,06			

Выводы:

- **Взаимодействие $A : B$ незначимо** ($F = 0,32 < 3,29$).
- **Фактор A незначим** ($F = 1,88 < 3,09$) при полной модели со взаимодействием.
- **Фактор B значим** ($F = 5,68 > 3,13$, $P < 0,001$).
- Совместное влияние факторов значимо ($F = 6,13 > 2,99$).

2.5 Задание E. Выбор наилучшей модели (AIC и BIC)

Модель	AIC	BIC
Полная $A \times B$	170,55	204,32
Аддитивная $A + B$	154,69	169,89
Только B	174,63	183,08
Только A	205,16	215,29
Константа	207,90	211,28

По критериям AIC и BIC наилучшей является **аддитивная модель $A + B$** .

2.6 Задание F. Интерпретация результатов

1. Несмещённая оценка дисперсии $s^2 = 3,06$.
2. Взаимодействие факторов A и B **статистически незначимо** ($P = 0,973$). Линии на графике взаимодействия практически параллельны — модель аддитивна.
3. Остатки **нормально распределены** (тест χ^2 принят, $P = 0,935$).
4. Фактор B оказывает **значимое** влияние на Y ($P < 0,001$). Фактор A незначим в полной модели.
5. По AIC и BIC оптимальна **аддитивная модель $Y \sim A + B$** , что согласуется с незначимостью взаимодействия.
6. **Вывод:** уровень фактора B существенно определяет среднее значение Y ; фактор A в данном эксперименте влияния не оказывает.